

# Filtro de Kalman em um robô 1D

Glauber R. Leite

## Modelagem do problema

Consideramos um robô 1D descrito pela seguinte equação diferença:

$$\frac{v_r(k+1) - v_r(k)}{T} = \frac{u(k)}{m}$$

Em que  $v_r$  é a velocidade,  $u(k)$  é a entrada de força,  $m$  é a massa do robô e  $T$  é o tempo de amostragem.

considerando  $x_r$  a posição do robô, temos o seguinte vetor de estados:

$$x = [x_r \quad v_r]^T$$

A partir da equação de velocidade, calculamos  $x_r(k+1)$ :

$$v_r(k) = \frac{x_r(k+1) - x_r(k)}{T} \Rightarrow x_r(k+1) = 1 \cdot x_r(k) + T \cdot v_r(k) + 0 \cdot u(k)$$

A partir da equação diferença, calculamos  $v_r(k+1)$ :

$$v_r(k+1) = 0 \cdot x(k) + 1 \cdot v_r(k) + \left(\frac{T}{m}\right) \cdot u(k)$$

Assim, o processo é descrito pela seguinte equação:

$$x(k+1) = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} x(k) + \begin{bmatrix} 0 \\ T \\ m \end{bmatrix} u(k) + v(k)$$

De forma que  $v(k)$  é o ruído de processo.

Usando um sensor de velocidade, com ruído caracterizado por  $\omega(k)$ , temos a seguinte equação de saída:

$$y(k+1) = [0 \quad 1] x(k) + \omega(k)$$

## Dados do problema

```
m = 1;  
T = 0.5;  
V = [0.2, 0.05; 0.05, 0.1]; % Process noise covariance matrix  
W = 0.5; % Output noise variance
```

Matrizes da modelagem fenomenológica:

```
F = [1, T; 0, 1];
G = [0; T/m];
H = [0, 1];
```

O problema original trabalha com apenas uma iteração.. Como a atividade requer mais iterações. Vamos definir um número de iterações:

```
n_iter = 20;
```

Usaremos as condições iniciais originalmente descritas, mas para que tenhamos mais iterações será necessário especificar mais valores de entrada e saída que o sistema receberia durante essas iterações. Esses valores foram escolhidos arbitrariamente construindo um cenário aonde o robô vai parando.

```
% No more voltage
u = zeros(n_iter, 1);
```

Estimativa inicial e matriz de incerteza (oferecida no problema):

```
x = zeros(2, n_iter);
x(:, 1) = [2; 4];
P = zeros(2, 2, n_iter);
P(:, :, 1) = [1, 0; 0, 2];
```

Sabendo que o estado real na primeira iteração é  $x(k+1) = [1.8 \ 2]^T$ . Definimos o vetor de velocidades supostamente retornadas pelo sensor no decorrer das iterações, quando a velocidade do carro vai diminuindo, além de adicionar *White Gaussian Noise* com variância  $W = 0.5$

```
% Based on the first real state, we compute the first ideal sensor reading
x_real = [1.8; 2];
y = zeros(n_iter, 1);
y(1) = H * x_real;
y(2) = y(1); % Just for later didactic purposes

% y must be zero at last iteration
dy = y(2)/(n_iter - 2);

for k = 3:n_iter
    y(k) = y(k-1) - dy;
end

% Adding White Gaussian Noise with y as mean
noise = rand(n_iter, 1)*sqrt(W);
y = y + noise;
```

## Implementação do filtro de Kalman

Aplicando as equações demonstradas em sala, temos os passos de predição e correção. Na primeira iteração, temos:

### Predição

```
x(:, 2) = F*x(:, 1) + G*u(1);
P(:, :, 2) = F*P(:, :, 1)*F' + V;
```

Para visualizar a predição usamos o seguinte trecho de código:

```
% Choosing confidence level to plot
p = 0.95;
% Computing scale factor
s = - 2 * log(1 - p);

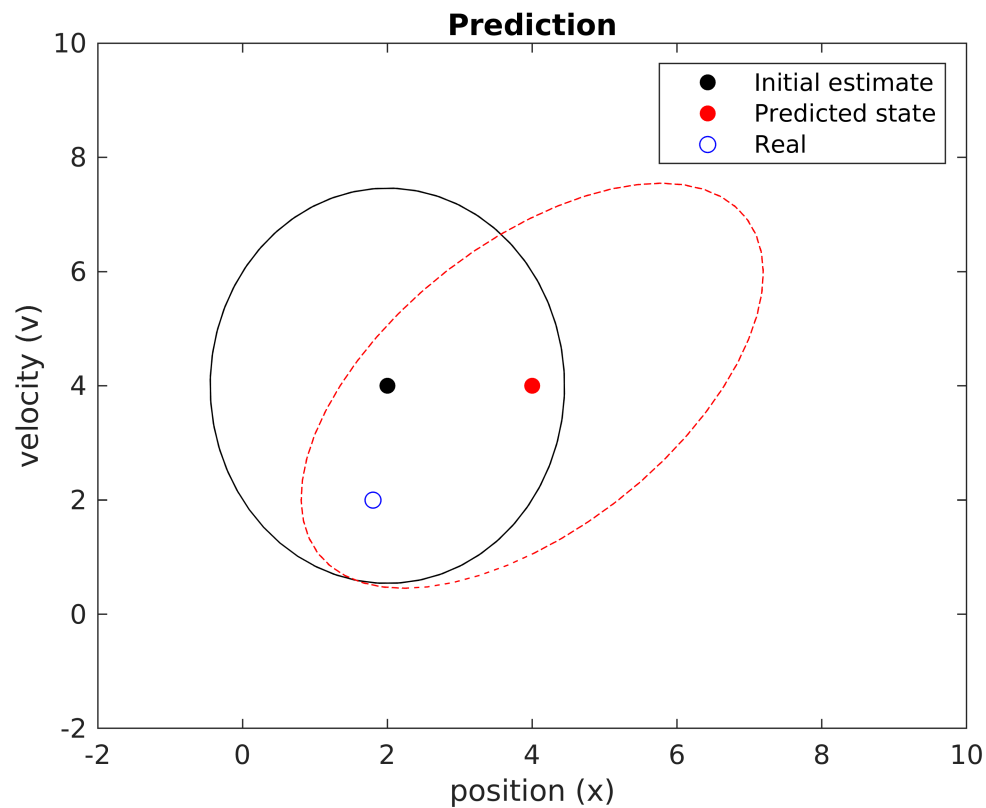
% Computing eigenvalues of eigenvectors uncertainty matrix P
[V1, D1] = eig(P(:, :, 1) * s);
[V2, D2] = eig(P(:, :, 2) * s);

% Ellipse equation
vel = linspace(-2,10);
a = (V1 * sqrt(D1)) * [cos(vel(:))'; sin(vel(:))'];
b = (V2 * sqrt(D2)) * [cos(vel(:))'; sin(vel(:))'];

% Plotting ellipses with x as mean
plot(a(1, :) + x(1,1), a(2, :) + x(2,1), 'k-');
hold on;
plot(b(1, :) + x(1,2), b(2, :) + x(2,2), 'r--');

% Adding states
s1 = scatter(x(1,1), x(2,1), 'k', 'filled');
s2 = scatter(x(1,2), x(2,2), 'r', 'filled');
s3 = scatter(x_real(1), x_real(2), 'b');

legend([s1, s2, s3], {'Initial estimate', 'Predicted state', 'Real'});
title('Prediction');
xlabel('position (x)');
ylabel('velocity (v)');
axis([-2 10 -2 10]);
hold off;
```



## Correção

```
R = P(:, :, 2) * H' / (H * P(:, :, 2) * H' + W);
nu = y(2) - H * x(:, 1);

% Saving predicted values (for plot)
x_predicted = x(:, 2);
P_predicted = P(:, :, 2);

x(:, 2) = x(:, 2) + R * nu;
P(:, :, 2) = P(:, :, 2) - R * H * P(:, :, 2);
```

Podemos plotar a iteração da seguinte maneira:

```
% Choosing confidence level to plot
p = 0.95;
% Computing scale factor
s = - 2 * log(1 - p);

% Computing eigenvalues of eigenvectors uncertainty matrix P
[V1, D1] = eig(P(:, :, 2) * s);
[V2, D2] = eig(P_predicted * s);

% Ellipse equation
vel = linspace(-2, 10);
a = (V1 * sqrt(D1)) * [cos(vel(:))'; sin(vel(:))'];
b = (V2 * sqrt(D2)) * [cos(vel(:))'; sin(vel(:))'];
```

```

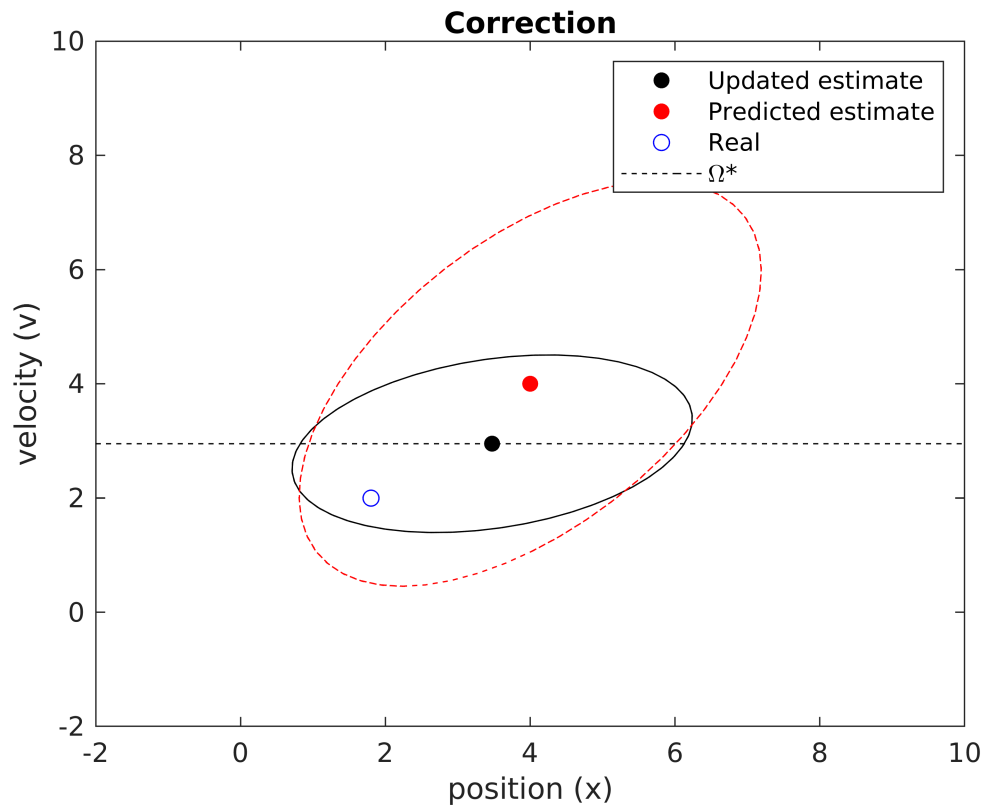
% Plotting ellipses with x as mean
plot(a(1, :) + x(1,2), a(2, :) + x(2,2), 'k-');
hold on;
plot(b(1, :) + x_predicted(1), b(2, :) + x_predicted(2), 'r--');

% Adding states
s1 = scatter(x(1,2), x(2,2), 'k', 'filled');
s2 = scatter(x_predicted(1), x_predicted(2), 'r', 'filled');
s3 = scatter(x_real(1), x_real(2), 'b');

omega = ones(length(v), 1) * x(2,2);
o1 = plot(v, omega, 'k--');

legend([s1, s2, s3, o1], {'Updated estimate', 'Predicted estimate', 'Real', '\Omega*'});
title('Correction');
xlabel('position (x)');
ylabel('velocity (v)');
axis([-2 10 -2 10]);
hold off;

```



Agora aplicamos as iterações seguintes

```

for k = 3:n_iter
    % Prediction
    x(:, k) = F*x(:, k-1) + G*u(k-1);

```

```

P(:, :, k) = F*P(:, :, k-1)*F' + V;

% Correction
R = P(:, :, k)*H'/(H*P(:, :, k)*H' + W);
nu = y(k) - H*x(:, k-1);

x(:, k) = x(:, k) + R*nu;
P(:, :, k) = P(:, :, k) - R*H*P(:, :, k);
end

% Choosing confidence level to plot
p = 0.95;
% Computing scale factor
s = - 2 * log(1 - p);

for k = 3:n_iter
    % Computing eigenvalues of eigenvectors uncertainty matrix P
    [V1, D1] = eig(P(:, :, k-1) * s);
    [V2, D2] = eig(P(:, :, k) * s);

    % Ellipse equation
    vel = linspace(-2, 20);
    a = (V1 * sqrt(D1)) * [cos(vel(:))'; sin(vel(:))'];
    b = (V2 * sqrt(D2)) * [cos(vel(:))'; sin(vel(:))'];

    % Plotting ellipses with x as mean
    figure
    plot(a(1, :) + x(1, k-1), a(2, :) + x(2, k-1), 'k-');
    hold on;
    plot(b(1, :) + x(1, k), b(2, :) + x(2, k), 'r--');

    % Adding states
    s1 = scatter(x(1, k-1), x(2, k-1), 'k', 'filled');
    s2 = scatter(x(1, k), x(2, k), 'r', 'filled');

    legend([s1, s2], {'Initial estimate', 'Computed estimate'});
    title(['Iteration ', num2str(k-1)]);
    xlabel('position (x)');
    ylabel('velocity (v)');
    axis([-2 20 -2 20]);
    hold off;
end

```

